



House Price Prediction

Group C- Machine Learning
Project 3

12 January 2026

Background & Problem Statement

Penentuan harga rumah yang tidak akurat dapat mengakibatkan overpricing atau underpricing dengan dampak finansial signifikan.

Penjual, pembeli, dan investor berisiko salah mengambil keputusan karena harga dapat dipengaruhi oleh subjektif bukan pengambilan keputusan berbasis data (data-driven decision making). Kesalahan dalam menentukan harga ini bisa berdampak besar:

- Penjual bisa kehilangan potensi keuntungan
- Pembeli bisa overpay
- Investor bisa salah ambil keputusan

Berdasarkan kondisi tersebut, project ini berfokus untuk menjawab pertanyaan bisnis menggunakan machine learning pada Ames Housing Dataset untuk:

- Mengidentifikasi pola kompleks dalam data
- Mengurangi subjektivitas
- Menghasilkan prediksi harga yang lebih akurat



Objectives & Scope

Objectives

- Membangun model machine learning untuk memprediksi harga rumah secara akurat
- Membandingkan beberapa algoritma untuk menemukan model terbaik
- Mengevaluasi dan membandingkan kinerja model menggunakan metrik yang sesuai (R^2 , MAE, MAPE)

Scope

- Dataset: Ames Housing Dataset (Ames, Iowa, USA)
- Data mencakup ± 79 fitur properti (fisik, kualitas, lokasi)
- Fokus pada prediksi harga (SalePrice)
- Model yang digunakan: Linear Regression, Random Forest, XGBoost
- Evaluasi menggunakan R^2 , MAE, dan MAPE
 -



Dataset yang Digunakan	Ames, Iowa, US.
Dimensi Data	• 1460 data • 79 Feature • 1 Feature Target Sale Price
Fitur	• MSSubClass, MSZoning, LotFrontage, LotArea, Street, Alley, LotShape, LandContour, Utilities, LotConfig, LandSlope, • Neighborhood, Condition1, Condition2, BldgType, HouseStyle, OverallQual, OverallCond, YearBuilt, YearRemodAdd, RoofStyle, • RoofMatl, Exterior1st, Exterior2nd, MasVnrType, MasVnrArea, ExterQual, ExterCond, Foundation, BsmtQual, BsmtCond, • BsmtExposure, BsmtFinType1, BsmtFinSF1, BsmtFinType2, BsmtFinSF2, BsmtUnfSF, TotalBsmtSF, Heating, HeatingQC, • CentralAir, Electrical, 1stFlrSF, 2ndFlrSF, LowQualFinSF, GrLivArea, BsmtFullBath, BsmtHalfBath, FullBath, HalfBath, • BedroomAbvGr, KitchenAbvGr, KitchenQual, TotRmsAbvGrd, Functional, Fireplaces, FireplaceQu, GarageType, GarageYrBlt, • GarageFinish, GarageCars, GarageArea, GarageQual, GarageCond, PavedDrive, WoodDeckSF, OpenPorchSF, EnclosedPorch, 3SsnPorch, • ScreenPorch, PoolArea, PoolQC, Fence, MiscFeature, MiscVal, MoSold, YrSold, SaleType, SaleCondition, SalePrice
Target Variabel	• SalePrice
Missing Values	• 19 Feature Missing (7830 missing values)
Duplicates	• Tidak Ada

EDA & Data Preparation




1. Handling Missing Values

- 3 data numerik = LotFrontage, GarageYrBlt, MasVnrArea.
- 16 data categorical = PoolQC, MiscFeature, Alley, Fence, MasVnrType, FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond, BsmtExposure, BsmtFinType2, BsmtQual, BsmtCond, BsmtFinType1, Electrical.
- Mengisi missing value dengan mencari hubungan antara missing value dengan fitur lainnya sehingga data yang missing diisi dengan NA sesuai data description
- Mengisi missing value dengan median dari data tersebut

EDA & Data Preparation

2 Membuat Feature Baru

- `data['HouseAge'] = data['YrSold'] - data['YearBuilt']` // usia rumah saat dijual
- `data['RemodelAge'] = data['YrSold'] - data['YearRemodAdd']` // usia rumah sejak renovasi terakhir
- `data['GarageAge'] = data['YrSold'] - data['GarageYrBlt']` // usia garasi saat dijual
- `data['TotalSF'] = data['TotalBsmtSF'] + data['GrLivArea']` // total keseluruhan luas bangunan
- `data['TotalPorchSF'] = (data['OpenPorchSF'] + data['EnclosedPorch'] + data['ScreenPorch'])` // total luas teras
- `data['TotalBath'] = (data['FullBath'] + data['BsmtFullBath'] + 0.5 * data['HalfBath'] + 0.5 * data['BsmtHalfBath'])` // total luas kamar mandi
- `data['FireplaceScore'] = data['Fireplaces'] * data['FireplaceQu_Numeric']` // kombinasi kualitas perapian



EDA & Data Preparation

3. Label Encoding



- 11 Feature categorical diubah menjadi ordinal encoding berdasarkan tingkatan di data deskripsi
- 16 Feature categorical diubah menjadi label encoding dengan menggunakan bisnis understanding

5. Drop Feature

- 24 Feature di drop karena sudah diwakili di feature engineering dan juga nunique yang sama tinggi (> 93%)
- 17 Feature di drop karena low korelasi dibawah < 0.2

EDA & Data Preparation

- SaleType , HouseStyle
- LotArea, CentralAir
- RoofStyle, SaleCondition
- Electrical, PavedDrive
- BsmtUnfSF, TotalPorchSF
- BldgType, Condition1
- BedroomAbvGr, LotConfig
- LandContour, Functional
- PoolArea, MoSold
- BsmtFinType2, BsmtFinSF2
- YrSold, LandSlope
- OverallCond, MSSubClass
- Fence, GarageAge
- LotShape, RemodelAge
- HouseAge



Model Development

- **Linear Regression**
- **Random Forest**
- **XGBoost**



Model Evaluation

	MAE Train	MAE Test	MAPE Train	MAPE Test	R-Square Train	R-Square Test	GAP MAPE	GAP R-Square
Linear Regression	20.224,97	20.923,82	12,06	12,23	82,99	85,15	0,17	2,16
Random Forest	6.479,54	17.862,05	3,79	10,70	98,14	88,81	6,91	9,34
XGBoost (Untuned)	700,83	17.771,32	0,46	10,84	99,98	89,73	10,38	10,26
XGBoost (Tuned)	8.465,46	16.463,42	5,42	9,83	97,51	90,25	4,41	7,26

Analisa :

- Linear regression adalah model dengan gap Mape dan gap R-square paling rendah. Konsisten dalam train dan test.
- Dibanding model lain linear regression Mape dan R-square nya paling rendah.
- Random forest Mape dan R-square mempunyai akurasi yang cukup baik tetapi gap nya lebih tinggi.
- XGboost untuned gap Mape dan gap R-square paling tinggi dibanding model lainnya.
- XGboost tuned merupakan model terbaik dengan gap Mape dan gap R-square yang cukup rendah dan juga nilai Mape dan R-square yang paling baik (Akurasi dan konsisten yang baik).

Model Evaluation

	MAE Train	MAE Test	MAPE Train	MAPE Test	R-Square Train	R-Square Test	GAP MAPE	GAP R-Square
XGBoost (Tuned)	8.465,46	16.463,42	5,42	9,83	97,51	90,25	4,41	7,26

- MAE menunjukkan rata-rata kesalahan prediksi model pada data baru, yaitu sekitar \$16,000 per rumah untuk di data test.
- Untuk Mape test dan train mempunyai akurasi yang sangat baik $< 10\%$ (menurut Lewis, 1982). Artinya model memiliki rata-rata error sekitar 9%, yang menunjukkan tingkat akurasi yang tinggi untuk prediksi harga properti.
- R-square 90,25% artinya model mampu menjelaskan 90,25% variasi SalePrice dari data, sisanya 9,75% dijelaskan oleh faktor lain yang tidak ada di model. Nilai 90,25% untuk prediksi harga rumah tergolong bagus, karena harga properti dipengaruhi banyak faktor subjektif yang sulit dikuantifikasi (selera pembeli, kondisi pasar, negosiasi).
- Gap Mape dan Gap R-square merupakan selisih antara train dan test. Model dengan GAP kecil menunjukkan kemampuan generalisasi yang lebih baik terhadap data baru. Dari matriks ini model stabil tidak overfitting.
- Model XGBoost tuned mengatasi overfitting dengan:
 - 1.Regularization (reg_alpha & reg_lambda)
 - 2.Pembatasan kompleksitas tree (max_depth, min_child_weight)
 - 3.Random sampling (subsample, colsample_bytree)
 - 4.Learning rate kecil (shrinkage)

Feature Importance

No	Feature	Importance Percentage
1	OverallQual	36,19
2	TotalSF	14,03
3	KitchenQual	7,90
4	GarageCars	6,60
5	Neighborhood	5,27
6	GarageFinish	3,84
7	TotalBath	3,32
8	BsmtQual	2,98
9	GarageType	1,82
10	CentralAir	1,79

Analisa :

- 🏆 Top driver harga rumah:
 - OverallQual → paling dominan (36%)
 - 👉 kualitas bangunan = faktor utama harga
- 🥈 Faktor ukuran:
 - TotalSF
 - 👉 luas rumah = driver kedua terbesar
- 🥉 Faktor fasilitas:
 - Kitchen, Garage, Bathroom
 - 👉 menunjukkan kenyamanan & fungsi rumah
- 📍 Faktor lokasi:
 - Neighborhood
 - 👉 lokasi tetap penting tapi tidak dominan dibanding kualitas

Conclusion

- Total data : 1.460 baris - Target : SalePrice (harga jual rumah) - Range harga : \$34,900 – \$755,000 - Rata-rata : \$180,921 | Median: \$163,000 - Distribusi : RIGHT-SKEWED → mean > median, ekor panjang ke kanan akibat rumah mewah bernilai tinggi
- Dari model ML yang kami training model yang menjadi terbaik : **XGboost tuned**. MAPE 9,83, R-squared 90,25. Gap MAPE 4,41 dan GAP R-squared 7,26
- MAPE 90,25 % menunjukkan tingkat akurasi yang tinggi menurut Lewis, 1982.
- Top Feature importance : OverallQual, TotalSF, KitchenQual, GarageCars, Neighborhood.



Real-World Application

1. PLATFORM PROPERTI ONLINE (seperti Rumah123, Lamudi, Zillow)

- Model prediksi harga otomatis saat penjual listing properti
- Input: luas, lokasi, kualitas bangunan → Output: estimasi harga wajar
- Manfaat: membantu penjual menentukan harga kompetitif, pembeli tahu apakah harga listing terlalu mahal/murah

2. PENILAIAN PROPERTI (Appraisal) UNTUK KPR / BANK

- Bank/lembaga keuangan menggunakan model untuk verifikasi nilai agunan sebelum menyetujui kredit pemilikan rumah

3. INVESTASI PROPERTI

- Investor bisa identifikasi properti undervalued:
harga aktual << harga prediksi model → potensi keuntungan

4. ASURANSI PROPERTI

- Perusahaan asuransi menentukan premi berdasarkan nilai properti
- Model membantu estimasi nilai penggantian yang lebih akurat

5. PEMERINTAH / PAJAK BUMI DAN BANGUNAN (PBB)

- Automated Mass Appraisal (AMA) untuk menentukan NJOP secara konsisten dan transparan di seluruh wilayah
- Mengurangi subjektivitas dan potensi korupsi penilaian manual



Feature Improvement

- Untuk keperluan dataset bisa menggunakan dataset yang ada
- Potensi untuk meningkatkan performa model dengan menggabungkan feature yang mirip di feature importance





Thank you